Documentação Técnica e Conceitual: Motor de Nowcasting Eleitoral Urna a Urna (TSE 2026)

Uma implementação independente de nowcasting eleitoral inspirada na abordagem de Rodrigo Mahlmeister e nas projeções de Rafael Fonteles, utilizando inferência ecológica NNLS regionalizada, pós-estratificação por UF e um ensemble dinâmico de transferência de votos e regressão hierárquica de swing.

Motivação e Inspiração: Este projeto foi construído de forma 100% independente após acompanhar as reportagens na imprensa sobre o modelo de projeção de Rodrigo Mahlmeister e o histórico das projeções matemáticas do governador do Piauí, Rafael Fonteles. Sem ter acesso ao código-fonte ou repositório original desses trabalhos, o objetivo foi desenvolver do zero um motor estatístico baseado nas técnicas citadas nas matérias capaz de replicar esse nível de precisão usando os microdados públicos do TSE.

1. O Problema Central: Viés de Velocidade de Chegada e Pareamento em Painel

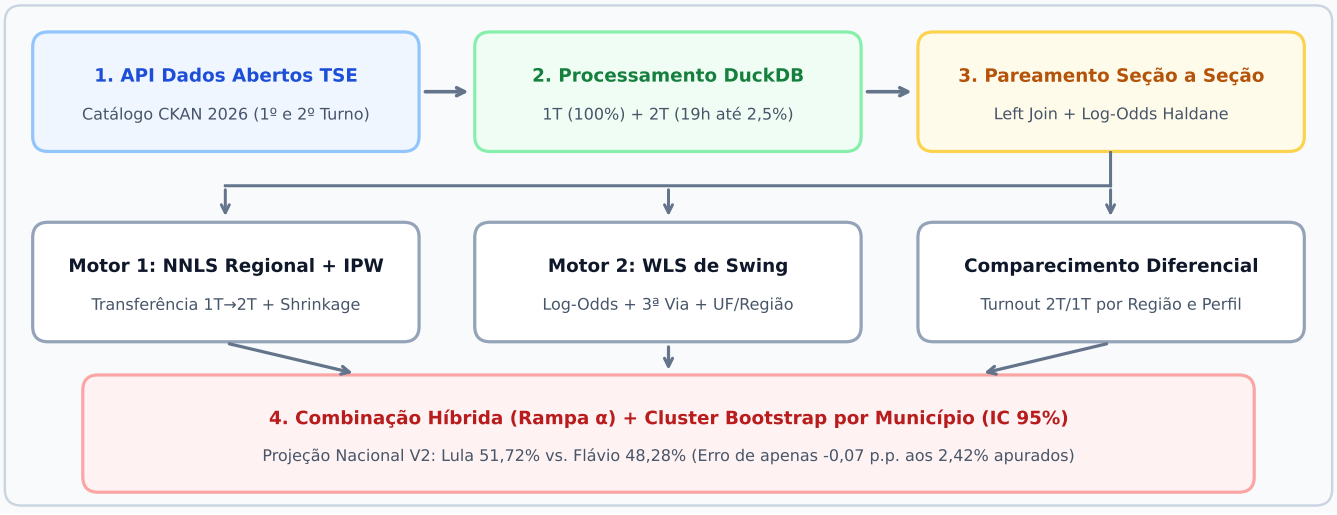
Quando o TSE inicia a divulgação dos resultados do 2º turno no começo da noite, as primeiras urnas recebidas pelos servidores **não constituem uma amostra aleatória do Brasil**. Seções eleitorais de capitais e centros urbanos informatizados do Sul, Sudeste e Centro-Oeste costumam transmitir seus Boletins de Urna antes de seções do interior do Nordeste ou de regiões remotas do Norte. Como a preferência partidária varia fortemente entre regiões, o placar bruto acumulado no início da apuração apresenta forte viés geográfico: aos **2,42% das seções apuradas** (às 19:21), o placar oficial bruto marcava **Lula 50,80% vs. Flávio 49,20%**, subestimando o resultado final de Lula (51,79%) em **-0,99 p.p.**

Para eliminar esse viés sem depender de pesquisas de boca de urna, o modelo explora uma informação censitária já conhecida: **o resultado exato de cada uma das ~472 mil seções eleitorais do país no 1º turno, ocorrido três semanas antes**. Em vez de projetar o resultado olhando apenas para quem lidera nas urnas já abertas, o algoritmo compara cada urna apurada no 2º turno com o resultado **dela mesma** no 1º turno, estima o padrão de variação (*swing*) e de migração dos eleitores da 3ª via por estado e região, e projeta individualmente as 97,58% de seções restantes.

Em termos formais, seja $U = \{1, \ldots, N\}$ a população finita de todas as seções eleitorais do Brasil ($N \approx 472.000$). No instante t, observamos apenas um subconjunto não-aleatório S_t ($|S_t|/N$ = 2,42%). Como a probabilidade de chegada correlaciona-se com a preferência partidária regional, os dados faltantes são *Missing Not At Random (MNAR)* em relação ao voto bruto, tornando o estimador ingênuo enviesado. Contudo, condicionando no vetor de covariáveis do 1º turno conhecido para 100% da população, $\mathbf{X_{i,0}} = (v_{A,i,0}, v_{B,i,0}, v_{Outros,i,0}, \mathbf{UF_i})$, o mecanismo de seleção torna-se *Missing At Random condicional (MAR)*:

$$\hat{P}_{bruto}(t) = \frac{\sum_{i \in S_t} v_{A,i,1}}{\sum_{i \in S_t} N_{i,1}}, \qquad I_i(t) \perp (v_{A,i,1}, v_{B,i,1}) \mid \mathbf{X}_{i,0}$$

2. Arquitetura do Pipeline de Engenharia de Dados (DuckDB + Parquet)



A preparação de dados em `preparar_dados_tse_2026` foi estruturada para processar dezenas de milhões de registros de Boletins de Urna com baixo consumo de memória:

- **Descoberta Automática de URLs via API CKAN (`obter_urls_bweb_2026`):** Como os arquivos brutos do TSE

(`bweb_1t_{UF}_{TIMESTAMP}.zip` e `bweb_2t_{UF}_{TIMESTAMP}.zip`) possuem sufixos de data/hora variáveis na CDN, o script consulta dinamicamente o catálogo `resultados-2026-boletim-de-urna` e faz o download apenas na primeira execução.

- **Ordenação Cronológica Estrita e Corte em 2,5% (`QUERY_2T_2026`):** O DuckDB converte `DT_BU_RECEBIDO` para `TIMESTAMP` real, preserva o gabarito nacional de 100% (`pct_A_real_100pct`) via *Window Function* (`totais_nacionais`), ordena a fila cronológica a partir das `19:00:00` até atingir `pct_urnas_acumulado <= 2.5%`, grava os microdados em Parquet (`br_2026_2t_crono_2_5pct.parquet`) e remove os CSVs brutos restantes.

3. Pareamento Granular Seção a Seção e Transformação Log-Odds

Para medir a variação de um candidato entre o 1º e o 2º turno em cada seção eleitoral, uma soma direta de pontos percentuais produziria distorções severas perto dos extremos: se um candidato já obteve 97% dos votos em uma urna no 1º turno e cresce +5 pontos na região, uma adição linear resultaria em 102% (impossível). Para evitar que projeções ultrapassem o intervalo [0%, 100%] e para capturar a desaceleração natural em redutos extremos, transformamos as proporções para a escala elástica de **Log-Odds** (razão logarítmica de chances), que varia livremente de -∞ a +∞.

Na função `parear_eleicoes`, unimos a base populacional do 1º turno (U) à amostra parcial do 2º turno (S_t) via *Left Join* pela chave primária composta `(SG_UF, CD_MUNICIPIO, NR_ZONA, NR_SECAO)`. Para cada seção i e turno $\tau \in \{0, 1\}$, aplicamos a transformação logit com a **correção de continuidade de Haldane-Anscombe (+0,5)** para prevenir divisão por zero em seções unânimes, definimos o *swing* observado $\Delta\ell_i$ e reconvertemos as predições pela função logística (sigmoide):

$$\ell_{i,\tau} = \ln\left(\frac{v_{A,i,\tau} + 0.5}{v_{B,i,\tau} + 0.5}\right), \quad \Delta\ell_i = \ell_{i,1} - \ell_{i,0}, \quad \hat{p}_{A,i,1} = \frac{1}{1 + e^{-\hat{\ell}_{i,1}}}$$

4. Motor 1: Inferência Ecológica de Transferência de Votos (NNLS + IPW)

No 1º turno, uma parcela expressiva do eleitorado vota em candidatos da 3ª via (`v_Outros_t0`). No 2º turno, esses votos migram para Lula ou Flávio em proporções muito distintas conforme a região do país, ao mesmo tempo em que os próprios finalistas apresentam taxas específicas de retenção de seus eleitores. O **Motor 1** estima essa matriz de transição comparando a composição de cada seção no 1º turno com seu resultado no 2º turno, impondo a restrição física de não-negatividade (nenhuma taxa de transferência pode ser menor que zero) e corrigindo a sobre-representação dos estados que apuram mais rápido.

Matematicamente, calculamos pesos de pós-estratificação por UF (*Inverse Probability Weighting - IPW*) comparando a participação da UF no eleitorado do 1º turno ($\pi_{u,pop}$) com sua participação nas urnas apuradas até o instante t ($\hat{\pi}_{u,St}$), e resolvemos o problema de **Mínimos Quadrados Não-Negativos (NNLS)** ponderado:

$$w_u = \text{clip}\left(\frac{\pi_{u,pop}}{\hat{\pi}_{u,S_t}}, 0.3, 4.0\right), \quad \hat{\beta}_k^{nac} = \arg\min_{\beta \geq 0} \|W^{1/2}(v_{k,1} - X_0\beta)\|_2^2$$

Para capturar a heterogeneidade espacial da migração da 3ª via sem sofrer com alta variância quando uma região tem poucas urnas abertas, estimamos vetores locais por Macrorregião r e aplicamos **Encolhimento Empírico-Bayesiano (Shrinkage de James-Stein)** em direção ao prior nacional ponderado:

$$\tilde{\beta}_k^{(r)} = \lambda_r \hat{\beta}_k^{(r)} + (1 - \lambda_r)\hat{\beta}_k^{nac}, \quad \lambda_r = \frac{n_r}{n_r + 120}$$

5. Motor 2: Regressão Linear Ponderada de Swing (WLS + Interação 3ª Via)

Complementando a matriz de transição em votos absolutos, o **Motor 2** modela diretamente o *swing* na escala Log-Odds ($\Delta\ell_i$), funcionando como um sensor fino de tendência geográfica e comportamental. Ele captura o efeito específico de cada Estado (`SG_UF`) e Macrorregião, o favoritismo prévio naquela seção no 1º turno ($\ell_{i,0}$) e a interação entre a fração de votos da 3ª via disponível na urna ($q_{i,0} = v_{Outros,i,0} / N_{i,0}$) e o alinhamento partidário local ($\ell_{i,0} \cdot q_{i,0}$) — refletindo o fenômeno ecológico em que o candidato dominante na vizinhança converte uma fatia maior dos eleitores da 3ª via. O ajuste por **Mínimos Quadrados Ponderados (WLS)** utiliza pesos $W_i = N_{i,0} \cdot w_{u(i)}$:

$$\Delta\ell_i = \beta_0 + \alpha_{reg(i)} + \gamma_{UF(i)} + \beta_1\ell_{i,0} + \beta_2 q_{i,0} + \beta_3(\ell_{i,0} \cdot q_{i,0}) + \varepsilon_i$$

A inclusão simultânea de efeitos fixos de Região (α_{reg}) e de UF (γ_{UF}), resolvida via decomposição SVD (pseudoinversa de Moore-Penrose no `statsmodels.WLS`), garante que UFs ainda sem urnas apuradas no início da noite herdem automaticamente o intercepto de sua Macrorregião em vez de colapsarem para zero. As predições individuais recebem amortecimento Empírico-Bayesiano em direção ao *swing* médio nacional ponderado:

$$\widetilde{\Delta\ell}_j = \omega \cdot \text{clip}(\widehat{\Delta\ell}_j^{WLS}, -0.8, 0.8) + (1-\omega)\overline{\Delta\ell}, \quad \omega = \frac{|S_t|}{|S_t| + 60}$$

6. Combinação Híbrida (Rampa α) e Comparecimento Diferencial (Turnout)

Para unir a estabilidade estrutural do Motor 1 (NNLS de Transferência) com a granularidade espacial do Motor 2 (WLS de Swing), o modelo combina as duas previsões por meio de uma rampa progressiva $\alpha(t)$ ativa desde os primeiros 0,5% das seções. À medida que a fração de urnas apuradas $f_t = |S_t| / N$ avança, o peso atribuído à regressão espacial cresce gradualmente de 35% até 85%:

$$\hat{p}_{A,j}^{comb} = (1-\alpha(t))\hat{p}_{A,j}^{transf} + \alpha(t)\hat{p}_{A,j}^{reg}, \quad \alpha(t) = \text{clip}\left(\frac{f_t - 0.005}{0.055}, 0.35, 0.85\right)$$

Além de prever a divisão percentual dos votos em cada seção faltante, é necessário prever **quantos eleitores compareceram** em cada urna no 2º turno, pois a variação na abstenção entre os dois turnos difere por região e perfil de urna. O comparecimento relativo $r_i = N_{i,1} / N_{i,0}$ é estimado via WLS em função da Região, $\ell_{i,0}$ e $q_{i,0}$, gerando o volume projetado $\hat{N}_{j,1} = N_{j,0} \cdot \tilde{r}_j$ e consolidando os votos reais já apurados com os votos projetados nas seções pendentes:

$$\hat{P}_{A,\,nacional} = \left(\frac{\sum_{i \in S_t} v_{A,i,1} + \sum_{j \notin S_t} \hat{N}_{j,1} \hat{p}_{A,j}^{comb}}{\sum_{i \in S_t} N_{i,1} + \sum_{j \notin S_t} \hat{N}_{j,1}} \right) \times 100$$

7. Quantificação de Incerteza: Cluster Bootstrap por Município (IC 95%)

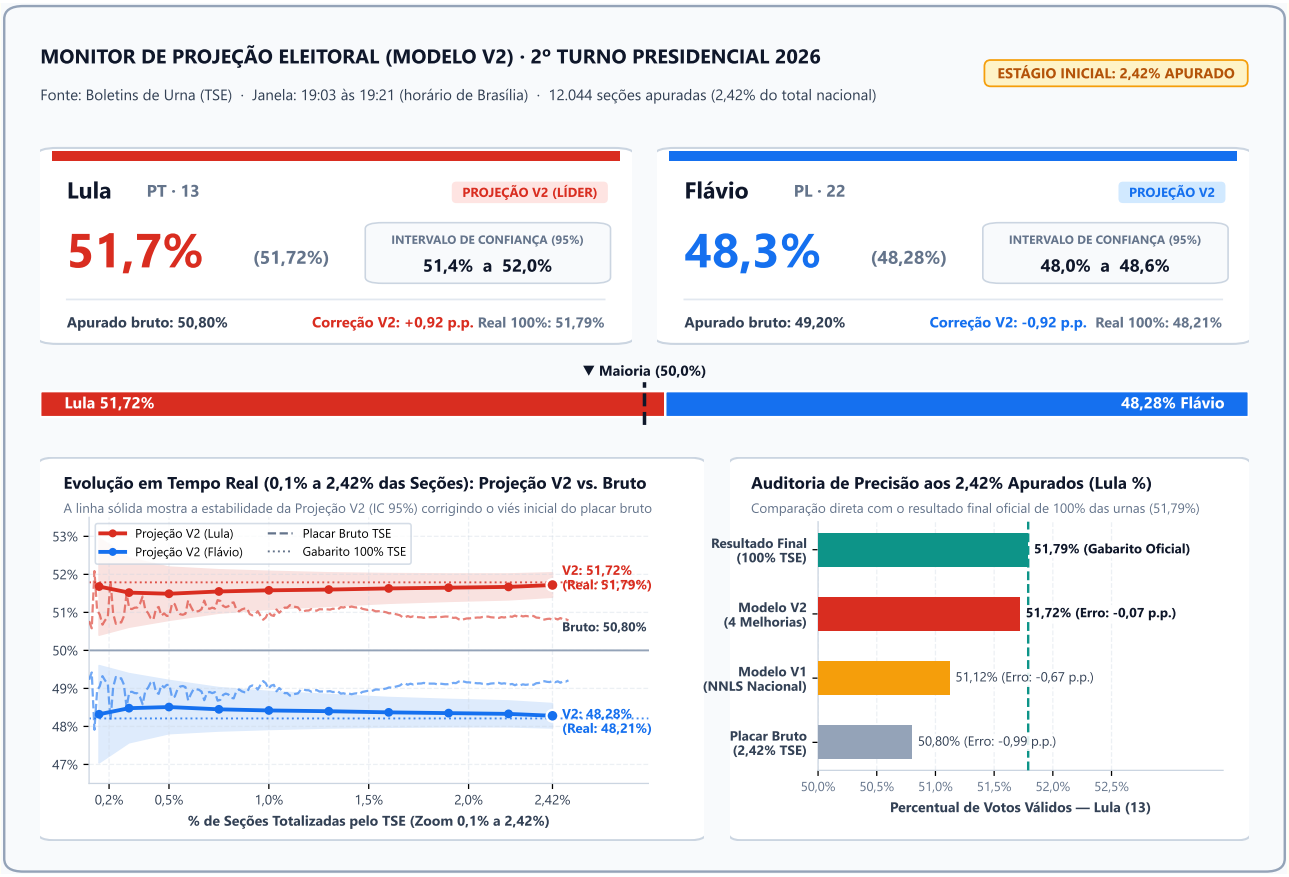
Seções eleitorais localizadas na mesma escola ou no mesmo município compartilham fortes choques locais, fazendo com que seus erros de previsão sejam positivamente correlacionados. Um *bootstrap* convencional que sorteasse urnas individuais como independentes subestimaria severamente a margem de erro. Para respeitar a dependência espacial intra-cluster, a função `cluster_bootstrap_municipio` realiza uma reamostragem em blocos: em cada uma das $B = 100$ réplicas, sorteiam-se **municípios inteiros com reposição** dentre os municípios presentes na amostra parcial e reexecuta-se todo o estimador híbrido do zero, extraindo os percentis 2,5% e 97,5% para formar a faixa de confiança de 95%.

8. Comparativo Empírico V1 vs. V2 (Eleições 2026 aos 2,42% Apurados)

Na **Versão 1 (V1)**, a rampa de transição iniciava apenas aos 5% das seções apuradas ($\alpha = 0$ abaixo de 5%), desativando a regressão espacial por UF durante toda a janela de 0% a 2,5% e deixando a projeção restrita a um NNLS nacional sem estratificação geográfica e sem modelo de comparecimento diferencial. Com as quatro melhorias metodológicas da **Versão 2 (V2)**, o erro absoluto caiu de -0,67 p.p. para apenas **-0,07 p.p.** aos 2,42% apurados:

Métrica / Modelo (aos 2,42% - 19:21)	Lula (13)	Flávio (22)	IC 95% (Lula)	Erro vs. 100% TSE (51,79%)
Placar Bruto Oficial TSE	50,80%	49,20%	—	-0,99 p.p.
Modelo V1 (NNLS Nacional Puro)	51,12%	48,88%	50,8% – 51,5%	-0,67 p.p.
Modelo V2 (Híbrido + 4 Melhorias)	**51,72%**	**48,28%**	**51,4% – 52,0%**	**-0,07 p.p.**
Resultado Oficial Final (100% TSE)	**51,79%**	**48,21%**	—	**0,00 p.p.**

9. Resumo Visual do Painel Executivo (`painel_projecao_2026_v2_dashboard.png`)



O painel de visualização executiva sintetiza a inferência estatística e a auditoria de precisão do Modelo V2 em quatro blocos visuais complementares:

- **1. Cabeçalho de Monitoramento e Selo de Estágio (Topo):** Identifica a fonte oficial (Boletins de Urna do TSE), a janela temporal exata da amostra (**19:03 às 19:21**, horário de Brasília) e o volume processado (**12.044 seções apuradas**, equivalentes a **2,42% do total nacional**), acompanhado do selo de alerta *"ESTÁGIO INICIAL: 2,42% APURADO"*.
- **2. Cards de KPI por Candidato e Termômetro de Maioria 50% (Centro Superior):**
  - **Card Lula (PT · 13 — Vermelho):** Destaca a **Projeção V2 (Líder) de 51,7%** (51,72%), o **Intervalo de Confiança de 95% (51,4% a 52,0%)**, o placar bruto apurado naquele instante (**50,80%**), a correção de viés regional aplicada pelo modelo (**+0,92 p.p.**) e a referência do resultado real em 100% (**51,79%**).
  - **Card Flávio (PL · 22 — Azul):** Destaca a **Projeção V2 de 48,3%** (48,28%), o **Intervalo de Confiança de 95% (48,0% a 48,6%)**, o apurado bruto parcial (**49,20%**), a correção do modelo (**-0,92 p.p.**) e o resultado real em 100% (**48,21%**).
  - **Barra Horizontal de Maioria (50,0%):** Representa visualmente a divisão nacional projetada (**51,72% vs. 48,28%**) em relação à linha divisória central de 50,0% dos votos válidos.
- **3. Gráfico Inferior Esquerdo — Evolução em Tempo Real (0,1% a 2,42% das Seções):** Compara lote a lote a **Projeção V2** (linha sólida com banda sombreada de IC 95%) contra o **Placar Bruto TSE** (linha tracejada) e o **Gabarito 100% TSE** (linha pontilhada horizontal). Demonstra que, enquanto o voto bruto permanece subestimando Lula ao redor de 50,80%, a Projeção V2 corrige o viés desde 0,2% das urnas e mantém-se estável em **51,72%**, colada na linha do resultado final real (51,79%).
- **4. Gráfico Inferior Direito — Auditoria de Precisão aos 2,42% Apurados (Lula %):** Compara diretamente em barras horizontais os quatro patamares contra a linha vertical do gabarito oficial:
  - **Resultado Final (100% TSE):** `51,79%` (Gabarito Oficial — Verde)
  - **Modelo V2 (4 Melhorias):** `51,72%` (Erro residual de apenas **-0,07 p.p.** — Vermelho)
  - **Modelo V1 (NNLS Nacional):** `51,12%` (Erro de **-0,67 p.p.** — Laranja)
  - **Placar Bruto (2,42% TSE):** `50,80%` (Erro de **-0,99 p.p.** — Cinza)